APACHE HUDİ

Mehmet PEKER
02210224054
Yazılım Mühendisliği

APACHE HUDI NEDIR

 Apache Hudi (Hadoop Upserts, Deletes, and Incrementals), büyük veriler üzerinde veri güncellemeleri, silme işlemleri ve inkremental veri işleme işlemleri sağlayan açık kaynaklı bir framework'tür. Hadoop ekosisteminin önemli bir parçasıdır ve Apache Spark ve Apache Hive ile entegre çalışır.

Apache Hudi Mimarisi Temel Bileşenler

Apache Hudi, aşağıdaki ana bileşenlerden oluşur:

- Hudi Core: Temel işleme, veri yönetimi ve hatalarla başa çıkma işlemleri burada yapılır.
- Hudi Write Client: Verilerin yazılması ve işlenmesi işlemleri.
- Hudi Query Client: Verilerin sorgulanması ve okunması işlemleri.
- Hudi DeltaStreamer: İnkremental veri akışlarını yönetir.

Apache Hudi'nin Çalışma Prensibi

- Veri Kaynağı: Hudi, HDFS, S3, Kafka, HBase gibi veri kaynaklarından veri alabilir.
- Veri İşleme: Veriler üzerinde upsert, delete ve inkremental işlemler yapılır.
- Veri Depolama: İşlenen veriler hedef depolama sistemine (HDFS, S3 vb.) yazılır.

Çalışma Akışı:

- Veriler alınır.
- Güncellemeler veya eklemeler yapılır.
- Veriler hedef sisteme yazılır.

Apache Hudi'nin Kütüphaneleri ve Fonksiyonları

- Hudi Write Operations: Veri ekleme, güncelleme ve silme işlemlerini sağlar.
- Hudi Query Engine: Hudi verileri üzerinde sorgulama ve analiz yapar.
- Hudi DeltaStreamer: Verinin sürekli olarak güncellenmesini sağlayan bir bileşendir.

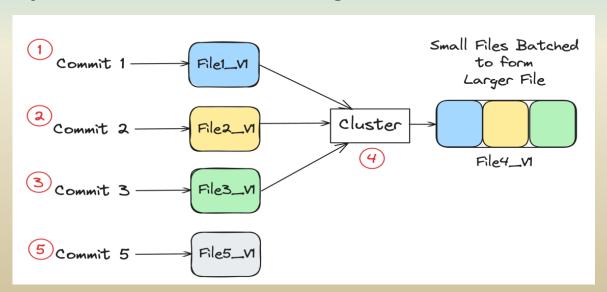
Hudi'nin Sağladığı Temel Özellikler:

- Upsert: Veri güncelleme ve ekleme işlemleri yapılır.
- Incremental Processing: Yalnızca değişen veriler işlenir.
- Veri Silme: Veriler üzerinde silme işlemleri yapılabilir

Apache Hudi Cluster Yönetimi

Apache Hudi, çeşitli cluster yönetim sistemleriyle uyumludur ve yüksek verimli veri işlemleri sağlar. İşte Hudi'nin desteklediği cluster yönetim yöntemleri:

- Standalone Cluster: Apache Hudi ile birlikte gelir ve basit bir cluster yönetimidir.
 Kaynak kullanımı sınırlıdır.
- Mesos Cluster: Dinamik kaynak yönetimi sağlar. Kaynak ihtiyacına göre kaynaklar artırılabilir veya azaltılabilir.
- Hadoop YARN Cluster: Hadoop ekosisteminin bir parçasıdır. Kaynak yönetimi otomatik olarak YARN tarafından yapılır.
- **Kubernetes Cluster:** Konteyner tabanlı mimarilerde kullanılabilir. Kaynak yönetimi, ölçeklenebilirlik ve esneklik sağlar



Hudi Write Client & Hudi Query Client

Hudi Write Client:

- Veri Yazma: Veriyi Hudi formatında hedef depolama alanına yazar.
- Upsert ve Append: Veriyi ekler veya günceller.

Hudi Query Client:

- Veri Okuma: Hudi üzerinde işlenen veriler üzerinde sorgulama yapılabilir.
- Veri İleri Düzey Analizi: Veri üzerinde analitik işlemler yapılabilir.

Apache Hudi: Hive ve Spark Entegrasyonu

- Hudi, Hive ile entegre çalışarak SQL tabanlı analiz yapılmasını sağlar.
- Apache Spark ile Hudi verileri üzerinde veri işleme ve analitik analizler yapılabilir.
- Hudi, HDFS üzerinde işlenen verileri hızlı bir şekilde sorgulama ve güncelleme yeteneği sağlar. Spark ve Hive ile Hudi'nin kullanımı performans açısından önemli avantajlar sunar.

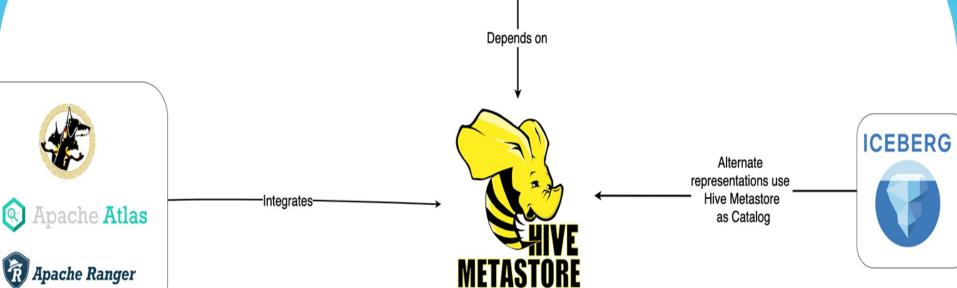












References data in









. . .

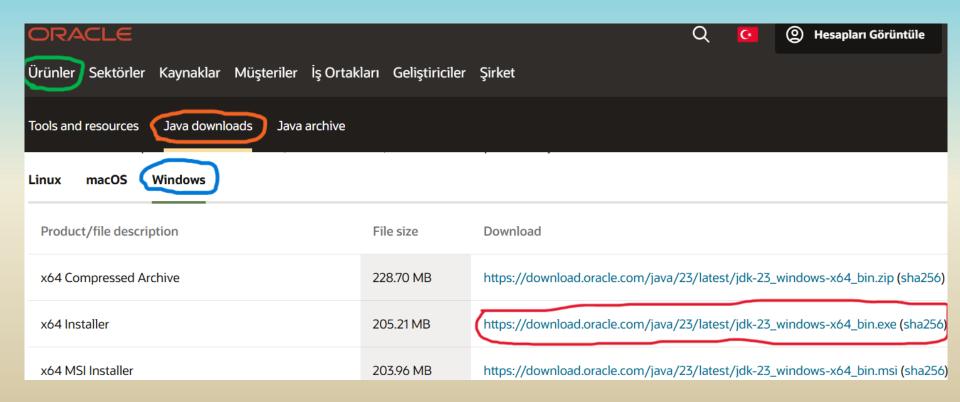
Apache Hudi'nin Avantajları

- Veri Güncellemeleri ve Silme: Apache Hudi, büyük veri üzerinde hızlı veri güncellemeleri ve silme işlemleri yapma yeteneği sunar.
- **Gerçek Zamanlı Veri Akışı:** İnkremental veri işleme ve gerçek zamanlı analiz yapma imkanı verir.
- Düşük Maliyet ve Yüksek Performans: Yalnızca değişen veriler işlenir, böylece kaynaklar verimli kullanılır ve performans artırılır.

APACHE HUDI KURULUM

Öncelikle Java Development Kit'i İndirelim.

- Oracle sitesinde Java downloads kısmından Windows'u seçelim.
- X64Installer seçeneğini seçip adım adım kuralım.



Apache Spark'ı İndirelim

 Apache Spark sitesine girip downloads kısmına girelim ve varsayılan seçeneklerle devam edelim.



Download Libraries ▼ Documentation ▼ Examples

Download Apache Spark™

- 1. Choose a Spark release: 3.5.3 (Sep 24 2024) ~
- 2. Choose a package type: Pre-built for Apache Hadoop 3.3 and later
- 3. Download Spark spark 3.5.3 bin hadoop 3.tgz

Spark indirmeye devam edelim



We suggest the following location for your download:

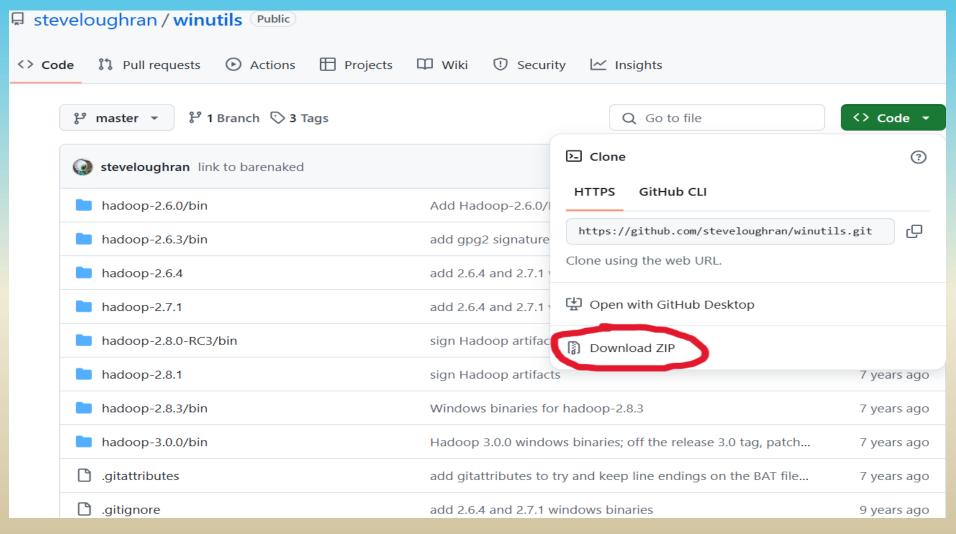
https://dlcdn.apache.org/spark/spark-3.5.3/spark-3.5.3-bin-hadoop3.tgz

Alternate download locations are suggested below.

It is essential that you verify the integrity of the downloaded file using the PC

Winutils(Hadoop) İndirelim

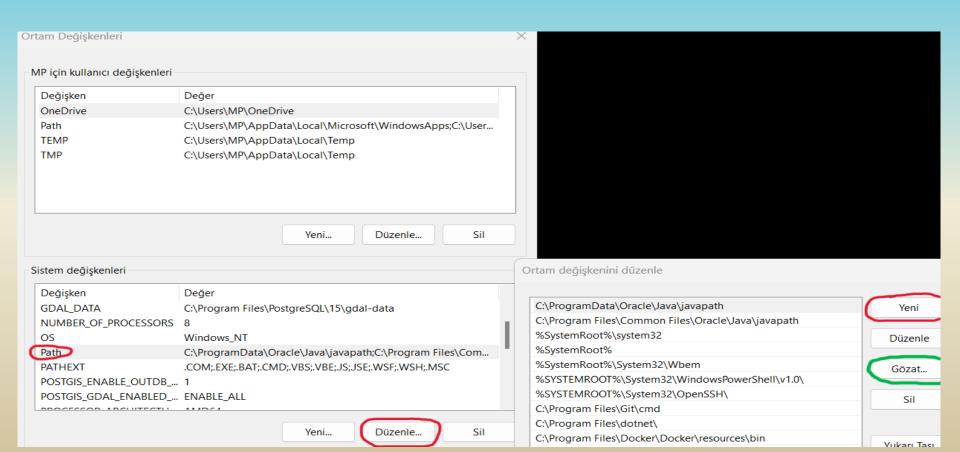
 Winutils Github linkinden zip dosyasını indiriyoruz ve son sürüm olan Hadoop/bin dosyasının içindekileri Spark dosyamızdaki bin dosyasının içerisine atıyoruz.



Ortam Değişkenlerini Ayarlayalım(Sistem Değişkenleri)

Sistem Değişkenleri:

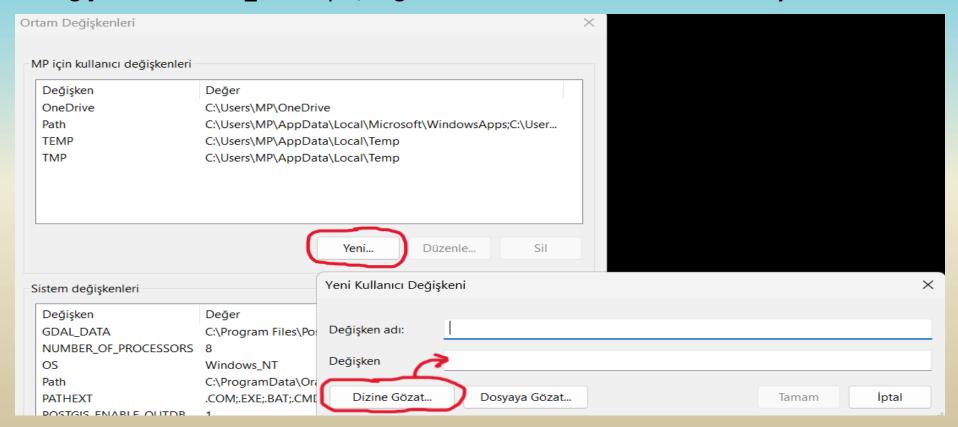
- Sistem/ Gelişmiş/ Ortam değişkenleri/ Sistem değişkenleri kısmından Path'i bulup düzenleye basalım, gözata basalım ve Spark/bin klasörünün dizin yolunu ekleyelim
- Sistem/ Gelişmiş/ Ortam değişkenleri/ Sistem değişkenleri kısmından Path'i bulup düzenleye basalım, yeniye basalım ve %JAVA_HOME%\bin yazısını ekleyelim
- Sistem/ Gelişmiş/ Ortam değişkenleri/ Sistem değişkenleri kısmından Path'i bulup düzenleye basalım yeniye basalım ve %HADOOP_HOME%\bin yazısını ekleyelim



Ortam Değişkenlerini Ayarlamaya Devam Edelim(Kullanıcı Değişkenleri)

Kullanıcı Değişkenleri:

- Sistem/ Gelişmiş/ Ortam değişkenleri/ Kullanıcı değişkenleri kısmından yeniye bas ve değişken adına SPARK_HOME yaz, değer kısmına Spark'ın dizin yolunu ekle
- Sistem/ Gelişmiş/ Ortam değişkenleri/ Kullanıcı değişkenleri kısmından yeniye bas ve değişken adına HADOOP_HOME yaz, değer kısmına Spark'ın dizin yolunu ekle
- Sistem/ Gelişmiş/ Ortam değişkenleri/ Kullanıcı değişkenleri kısmından yeniye bas ve
 değişken adına JAVA_HOME yaz, değer kısmına JAVA JDK klasörünün dizin yolunu ekle



Apache Spark ile Etkileşimli Komut Satırı Kullanımı

• CMD üzerinde spark-shell komutunu çalıştıralım.

entLog.gcMetrics.oldGenerationGarbageCollectors

```
×
   Administrator: Komut İsten × + ~
Microsoft Windows [Version 10.0.22631.4317]
(c) Microsoft Corporation. Tüm hakları saklıdır.
C:\Users\MP\spark-shell
24/11/10 20:37:16 WARN Shell: Did not find winutils.exe: java.io.FileNotFoun
dException: Hadoop bin directory does not exist: C:\Users\MP\Desktop\spark-3
.5.3-bin-hadoop3\bin\bin -see https://wiki.apache.org/hadoop/WindowsProblems
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLog
Level(newLevel).
Spark context Web UI available at http://DESKTOP-UTF03G3:4040
Spark context available as 'sc' (master = local[*], app id = local-173126024
0714).
Spark session available as 'spark'.
Welcome to
  /__/
_\\/_\/_\/_\/_\/
/__/.__/\_\/_\/\_\\ version 3.5.3
Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 21.0.2)
Type in expressions to have them evaluated.
Type :help for more information.
scala> 24/11/10 20:37:35 WARN GarbageCollectionMetrics: To enable non-built-
in garbage collector(s) List(G1 Concurrent GC), users should configure it(th
em) to spark.eventLog.gcMetrics.youngGenerationGarbageCollectors or spark.ev
```

A) Hudi'yi Bilgisayarınıza Kurmadan CMD Üzerinden Kullanabilirsiniz.

- Avantaj: Bu yöntem ile Hudi otomatik olarak güncellenmiş gelir.
- Dezavantaj: Bu yöntemde internet bağlantınızın olması gerekir.

B) Hudi'yi Bilgisayarınıza 2 Şekilde Kurabilirsiniz.

- Avantaj: Bu yöntemde Hudi'yi kullanırken internete bağlı olmanız gerekmez.
- **Dezavantaj:** Bu yöntemde Hudi'yi kullanırken otomatik güncelleme olmaz, manuel olarak güncellemeniz gerekir.
- 1- Hudi' yi manuel kurma: Bilgisayarınıza kurduğunuz Hudi'yi her seferinde CMD üzerinden çağırmanız gerekir
- **2- Hudi'yi otomatik kurma:** Spark başlatıldıgında Hudi otomatik olarak gelir ve ekstradan bir şey yazmanız gerekmez.

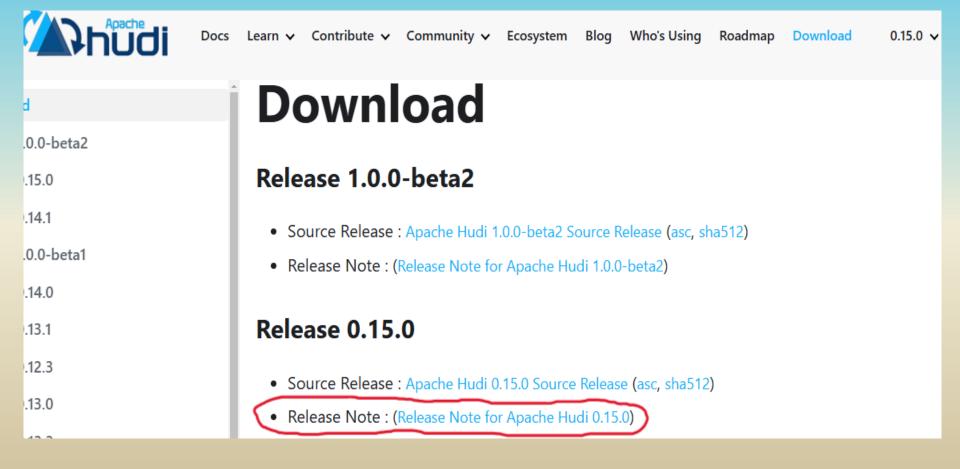
A) Spark Shell Üzerinde Hudi'yi Çağırma

CMD üzerinde spark-shell --packages org.apache.hudi:hudi-spark3.5-bundle_2.12:0.15.0
 komutunu çalıştırıyoruz. (scala içinde çalıştırmayınız)

```
Administrator: Komut İsten × + v
C:\Users\MP\spark-shell --packages org.apache.hudi:hudi-spark3.5-bundle_2.12:0.15.0
:: loading settings :: url = jar:file:/C:/Users/MP/Desktop/spark-3.5.3-bin-hadoop3/jars/ivy-2.5.1.jar!/org
/apache/ivy/core/settings/ivysettings.xml
Ivy Default Cache set to: C:\Users\MP\.ivy2\cache
The jars for the packages stored in: C:\Users\MP\.ivv2\jars
org.apache.hudi#hudi-spark3.5-bundle_2.12 added as a dependency
:: resolving dependencies :: org.apache.spark#spark-submit-parent-9a021a48-93f5-4194-a570-32e31444ebd5:1.0
        confs: [default]
        found org.apache.hudi#hudi-spark3.5-bundle_2.12;0.15.0 in central
        found org.apache.hive#hive-storage-api;2.8.1 in central
        found org.slf4j#slf4j-api;1.7.36 in local-m2-cache
:: resolution report :: resolve 170ms :: artifacts dl 10ms
        :: modules in use:
        org.apache.hive#hive-storage-api;2.8.1 from central in [default]
        org.apache.hudi#hudi-spark3.5-bundle_2.12;0.15.0 from central in [default]
        org.slf4j#slf4j-api;1.7.36 from local-m2-cache in [default]
                modules || artifacts |
conf | number| search|dwnlded|evicted|| number|dwnlded|
               default
:: retrieving :: org.apache.spark#spark-submit-parent-9a021a48-93f5-4194-a570-32e31444ebd5
        confs: [default]
        0 artifacts copied, 3 already retrieved (0kB/12ms)
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Spark context Web UI available at http://DESKTOP-UTF03G3:4040
Spark context available as 'sc' (master = local[*], app id = local-1731261557068).
Spark session available as 'spark'.
Welcome to
   Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 21.0.2)
```

B) Hudi'yi Bilgisayarınıza Kurmak İsterseniz

- Apache hudi resmi sayfasına girelim ve download butonuna basalım.
- Beta olmayan sürümlerden son sürümün altına gelelim ve release note linkine tıklayalım.



Hudi'yi Bilgisayara Kurmaya Devam

New spark bundles altında bizim kullandığımız scala versiyonunu seçelim.



Docs Learn ✓ Contribute ✓ Community ✓ Ecosystem Blog Who's Using Roadmap Downl

Download

Release 1.0.0-beta2

Release 0.15.0

Release 0.14.1

Release 1.0.0-beta1

Release 0.14.0

Bundle Updates

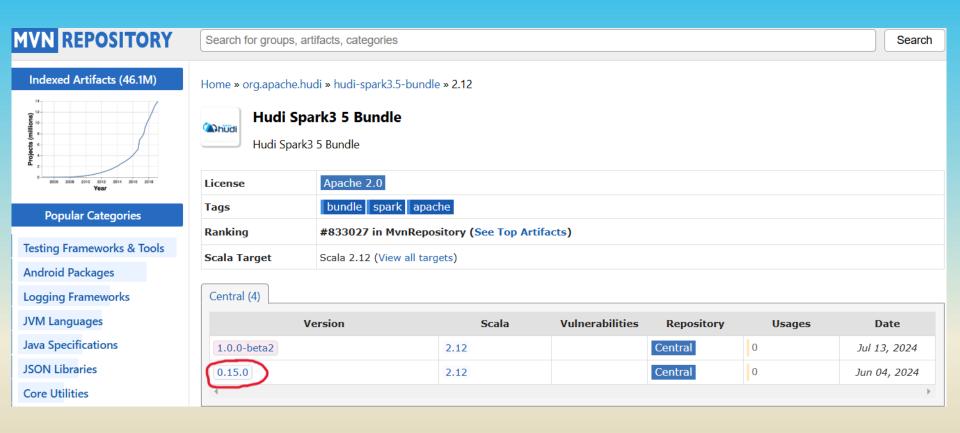
New Spark Bundles

We have expanded Hudi support to Spark 3.5 with two new bundles:

- Spark 3.5 and Scala 2.12 hudi-spark3.5-bundle_2.12
- Spark 3.5 and Scala 2.13: hudi-spark3.5-bundle_2.13

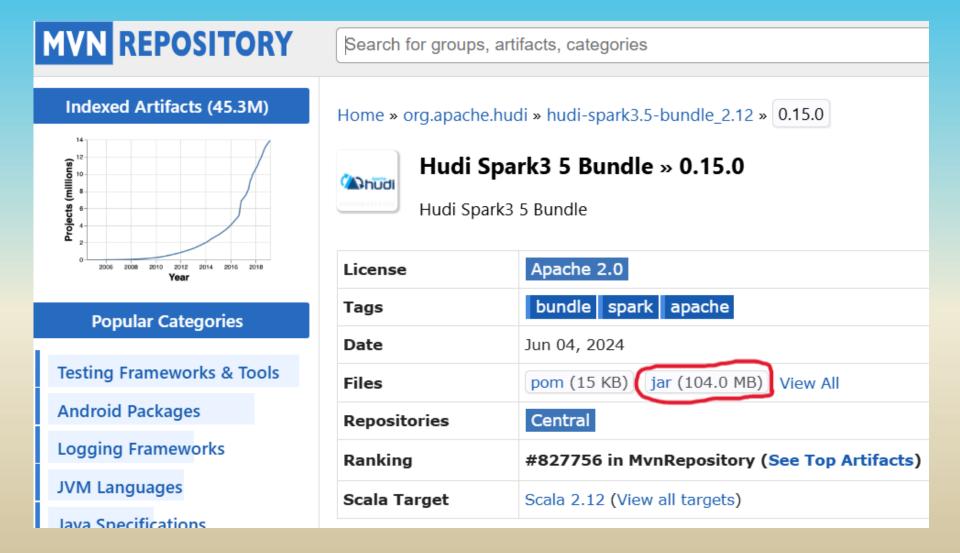
Hudi'yi Bilgisayara Kurmaya Devam

Normal olan sürümü(beta olmayanı) seçerek devam edelim.



Hudi'yi Bilgisayara Kurmaya Devam

- Açılan sayfadaki jar dosyasını indirelim.
- Yüklenen jar dosyasını spark içindeki jars klasörünün içerisine atalım.



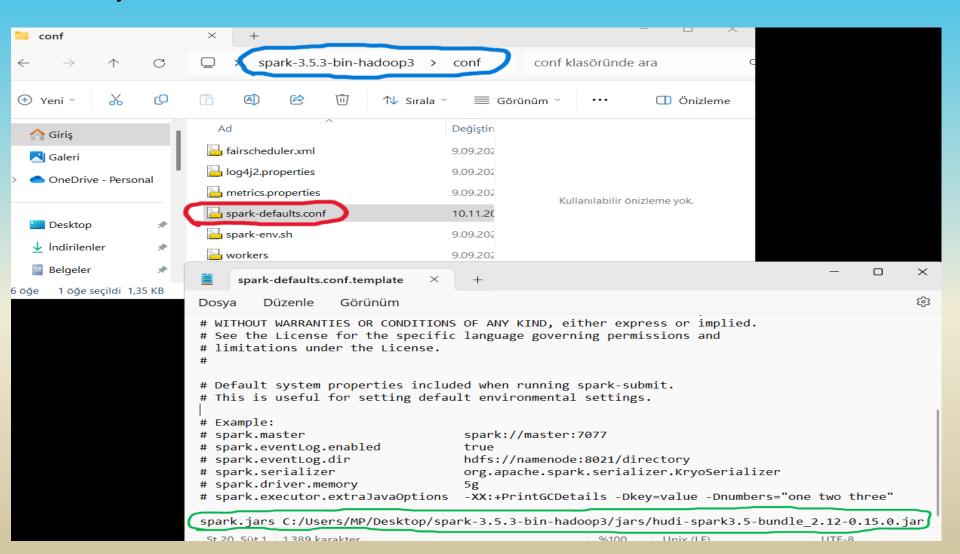
1- Hudi Manuel Kurulum Tamamlama

- Eğer Spark shell'i başlatırken .jar dosyasını manuel olarak eklemek isterseniz, aşağıdaki komutu kullanabilirsiniz: (Kendi dosya yolunuzu yazınız!)
- spark-shell --jars C:\Users\MP\Desktop\spark-3.5.3-bin-hadoop3\jars\hudi-spark3.5-bundle_2.12-0.15.0.jar

```
Administrator: Komut İsten × + -
Microsoft Windows [Version 10.0.22631.4317]
(c) Microsoft Corporation. Tüm hakları saklıdır.
C:\Users\MP>spark-shell --jars C:\Users\MP\Desktop\spark-3.5.3-bin-hadoop3\jars\hudi-spark3.5-bundle_2.12-0.15.0.jar
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Spark context Web UI available at http://DESKTOP-UTF03G3:4040
Spark context available as 'sc' (master = local[*], app id = local-1731268161329).
Spark session available as 'spark'.
Welcome to
   /__/_ ____//__
_\\/_\/_ \/_''_/
/__/.__/\_,_/_//_\\ version 3.5.3
Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 21.0.2)
Type in expressions to have them evaluated.
Type :help for more information.
scala> 24/11/10 22:49:32 WARN GarbageCollectionMetrics: To enable non-built-in garbage collector(s) List(G1 Concurre
nt GC), users should configure it(them) to spark.eventLog.gcMetrics.youngGenerationGarbageCollectors or spark.eventL
og.gcMetrics.oldGenerationGarbageCollectors
```

2- Hudi Otomatik Kurulum Tamamlama

- Eğer .jar dosyasını her Spark çalıştırmanızda otomatik olarak yüklemek isterseniz, Spark'ın conf klasöründeki spark-defaults.conf dosyasına aşağıdaki satırı ekleyin. Bu dosya yoksa aynı dizinde yeni bir spark-defaults.conf dosyası oluşturabilirsiniz. (Kendi dosya yolunuzu yazınız!)
- spark.jars C:/Users/MP/Desktop/spark-3.5.3-bin-hadoop3/jars/hudi-spark3.5-bundle_2.12-0.15.0.jar



Olası Hataların Çözümü:

- Aşağıdaki komutu kullanarak güvenlik yöneticisiyle ilgili hataları devre dışı bırakmayı deneyin:
- spark-shell --conf spark.driver.extraJavaOptions="-Djava.security.manager=allow"

APACHE HUDI ÖRNEK KODLAR

Apache Hudi ile Basit Veri Yazma

```
val data = Seq((1, "Alice", 23), (2, "Bob", 30))
val df = spark.createDataFrame(data).toDF("id", "name", "age")
df.write.format("hudi")
    .option("recordkey.field", "id") .option("partitionpath.field", "age")
    .option("table.name", "user_data") .mode("append")
    .save("/path/to/hudi/destination")
```

Açıklama: Bu kod, verileri Hudi formatında yazmak için kullanılır. İd alanı birincil anahtar, age ise veri bölümlendirme alanıdır.

Apache Hudi ile Veri Okuma

val hudiDF = spark.read.format("hudi").load("/path/to/hudi/destination/*")
hudiDF.show()

Açıklama: Bu kod, Hudi formatında yazılmış veriyi okur ve ekrana yazdırır.

Apache Hudi ile Veri Güncelleme (Upsert)

Açıklama: Bu kod, mevcut verileri güncelleyerek Hudi'ye yazar.

Apache Hudi ile Veri Silme

Apache Hudi'de Son Olarak:

- Apache Hudi, büyük veri yönetiminde esnek ve verimli çözümler sunan açık kaynaklı bir framework'tür.
- Veri Güncellemeleri, Silme ve İnkremental İşleme gibi işlemleri hızla ve düşük maliyetle gerçekleştirir.
- Cluster Yönetimi ve Entegrasyon: Apache Hudi, farklı cluster yönetim sistemleri ile entegrasyon sağlar ve büyük veri kümelerinde yüksek verimlilik sunar.